


Phân loại Hoạt động bằng Cảm biến Smartphone

Dự án Khoa học Dữ liệu: Từ Dữ liệu Thô đến Mô hình Học máy Triển khai thực tế

Tác giả: Trần Nhật Hưng - MSV: 24021507

Phát biểu Bài toán

- **Thách thức:** Tận dụng dữ liệu cảm biến khổng lồ từ thiết bị di động để phân tích hành vi người dùng một cách tự động.
- **Mục tiêu:** Xây dựng mô hình dự báo chính xác trạng thái hoạt động (đứng, ngồi, đi, v.v.) chỉ dựa vào dữ liệu thô.
- **Nguồn dữ liệu:** Cảm biến gia tốc kế (Accelerometer) và con quay hồi chuyển (Gyroscope) của smartphone.
- **Giá trị:** Hỗ trợ các ứng dụng theo dõi sức khỏe, fitness và nghiên cứu hành vi y tế.



Câu hỏi Nghiên cứu

- 01** Đối với dữ liệu cảm biến đo lường hành vi, có nên loại bỏ các điểm dữ liệu ngoại lệ (outliers) hay không?
- 02** Những đặc trưng nào có mức độ quan trọng cao nhất trong việc nhận diện hoạt động?
- 03** Mô hình học máy nào là lựa chọn tốt nhất để đạt được sự cân bằng giữa độ chính xác và hiệu năng?
- 04** Khi dùng Logistic Regression, thuật toán thường gặp khó khăn và nhầm lẫn nhiều nhất khi phân biệt trạng thái nào và nó có đáng tin cậy hay không?



Tổng quan Dữ liệu

10K+

Mẫu dữ liệu chất lượng

Khám phá Dữ liệu (EDA)

Bộ dữ liệu bao gồm **7,352** mẫu huấn luyện và **2,947** mẫu kiểm thử, hoàn toàn sạch (không chứa giá trị null hay trùng lặp).

Các lớp hoạt động (đi bộ, đứng, ngồi, nằm...) phân phối cực kỳ cân bằng, loại bỏ nhu cầu sử dụng các kỹ thuật phức tạp như SMOTE.

Tôi chủ động giữ lại các điểm ngoại lệ (outliers) vì chúng chứa tín hiệu quan trọng về các chuyển động đột ngột của người dùng.

Tiền xử lý Dữ liệu

Chuẩn hóa

Dùng StandardScaler đưa dữ liệu về phân phối chuẩn (mean=0, std=1).

Kết quả

Giảm số chiều dữ liệu mạnh mẽ từ 561 xuống còn 121 đặc trưng cốt lõi.



Mã hóa Nhãn

Chuyển đổi biến phân loại text sang số nguyên bằng LabelEncoder.




Chọn Đặc trưng

Dùng Random Forest & SelectFromModel lọc tín hiệu nhiễu.



Top 20 Tín hiệu Cảm biến có mức độ quan trọng cao



Huấn luyện Mô hình

Thuật toán Ứng viên

Ba mô hình phân loại đa lớp phổ biến được lựa chọn để đánh giá chéo:

- ✓ **Logistic Regression:** Nhanh, tuyến tính, dễ diễn giải.
- ✓ **Random Forest:** Dựa trên tập hợp cây quyết định, xử lý dữ liệu phi tuyến tốt.
- ✓ **SVM:** Thuật toán mạnh mẽ tối ưu ranh giới đa chiều.

Chiến lược Tinh chỉnh

Kỹ thuật tối ưu hóa siêu tham số (Hyperparameter Tuning):

- ✓ **GridSearchCV:** Tìm kiếm toàn diện cho Logistic Regression và SVM.
- ✓ **RandomizedSearchCV:** Tối ưu hiệu năng tính toán cho Random Forest.
- ✓ **KFold (k=5):** Kiểm định chéo với StratifiedKFold giữ tỷ lệ lớp.

So sánh Mô hình

Tên Mô hình	Train Accuracy	Test Accuracy	Độ Chênh lệch
Logistic Regression	~ 97.8%	~ 93.8%	~ 4.0% (Tốt nhất)
Support Vector Machine	~ 98.2%	~ 93.0%	~ 5.2%
Random Forest	100.0%	~ 91.3%	~ 8.7% (Overfitting)

**Độ chênh lệch thấp cho thấy mô hình không bị "học vẹt" (overfitting) và có khả năng tổng quát hóa dữ liệu mới rất tốt.*

Lựa chọn Tối ưu

Tại sao chọn Logistic Regression?



Cân bằng hoàn hảo

Đạt độ chính xác cao nhất trên tập kiểm thử (**93.8%**), mô hình còn giữ được độ chênh lệch Train/Test thấp nhất (**4%**).



Tránh Overfitting

Khắc phục nhược điểm của Random Forest (học thuộc lòng 100% dữ liệu huấn luyện nhưng giảm xuống 91.3% khi kiểm thử).



Độ tin cậy cao

Mô hình đơn giản, tốc độ suy luận nhanh và cực kỳ ổn định trong môi trường thực tế hạn chế tài nguyên phần cứng.

Classification Report

Hoạt động	Precision	Recall	F1-Score	Support
LAYING	1.00	0.99	1.00	537
SITTING	0.92	0.85	0.88	491
STANDING	0.87	0.93	0.90	532
WALKING	0.94	0.99	0.96	496
WALKING_DOWNSTAIRS	1.00	0.92	0.96	420
WALKING_UPSTAIRS	0.92	0.94	0.93	471

Mô hình hoạt động xuất sắc (>0.93 F1-score) trên hầu hết các lớp. Sự nhầm lẫn nhẹ giữa **SITTING** và **STANDING** do tính chất cảm biến tĩnh tương đồng.

Confusion Matrix



Quan sát chính

Sự nhầm lẫn lớn nhất xảy ra giữa hai trạng thái tĩnh:

SITTING & STANDING

109

Trường hợp nhầm lẫn

Nguyên nhân: Cả hai đều là hoạt động tĩnh với tín hiệu cảm biến tương tự, gây khó khăn cho việc phân loại chính xác tuyệt đối.

Brier Score Analysis


Hoạt động	Brier Score
LAYING	0.001061
WALKING	0.010308
WALKING_DOWNSTAIRS	0.010752
WALKING_UPSTAIRS	0.018951
STANDING	0.025239
SITTING	0.026068

Brier score trung bình (macro avg) là **0.015**, một con số rất thấp, khẳng định thêm rằng các dự đoán xác suất của mô hình là đáng tin cậy.

Demo & Mục tiêu

Mô hình được lưu trữ an toàn qua joblib (model, scaler, selector) để tái sử dụng. Bản demo Streamlit đã sẵn sàng để dự đoán trực quan.

Hướng tới tương lai, tôi đặt mục tiêu tích hợp mô hình vào ứng dụng di động theo thời gian thực và mở rộng nhận diện các hoạt động phức tạp như đạp xe.



Hỏi & Đáp

Cảm ơn thầy và các bạn đã lắng nghe phần trình bày dự án.